

# Gestion de la mémoire

Stéphanie Moreaud

Département d'informatique  
IUT Bordeaux 1

# Plan

- 1 Introduction
- 2 Partage de la mémoire
- 3 Adresses logiques
- 4 Gestion de l'allocation contiguë
- 5 Swapping
- 6 Segmentation
- 7 Espace mémoire paginé
- 8 Mémoire virtuelle paginée
- 9 Algorithmes de remplacement de page
- 10 Mémoire virtuelle segmentée paginée

# Bibliographie



TANENBAUM (A.), *Systèmes d'exploitation*. Pearson Education.



BILLAUD (M.), *Cours de ASR2-Système*.

<http://www.labri.fr/perso/billaud/>.

Remerciements à Michel Billaud.

# Plan

- 1 Introduction
  - Systèmes et mémoire
- 2 Partage de la mémoire
- 3 Adresses logiques
- 4 Gestion de l'allocation contiguë
- 5 Swapping
- 6 Segmentation
- 7 Espace mémoire paginé
- 8 Mémoire virtuelle paginée
- 9 Algorithmes de remplacement de page
- 10 Mémoire virtuelle segmentée paginée

# Ressource mémoire

**Mémoire** : ressource essentielle au fonctionnement d'un ordinateur qui permet le stockage des informations.

L'évolution des ordinateurs s'accompagne de l'augmentation de la puissance de calcul et de la mémoire disponible...  
... mais plus il y a de ressources disponibles, plus les programmes sont gourmands.

- les besoins en mémoire augmentent aussi vite que la taille de celle-ci...
- la mémoire doit être gérée avec soin.

**Objectif du cours** : comprendre comment les systèmes d'exploitation gèrent la mémoire.

# Ressource mémoire

Les programmeurs voudraient une mémoire :

- infiniment grande
- extrêmement rapide
- non volatile
- bon marché

→ de telles mémoires n'existent pas...

On utilise des compromis

- plusieurs types de mémoire, différentes caractéristiques
  - très rapide / moins rapide
  - volatile / non volatile
  - chère / bon marché
- organisation hiérarchique

# Hiérarchie mémoire

L'information est stockée dans plusieurs niveaux de mémoire

- **Registres**
  - interne au CPU, capacité  $< 1\text{Ko}$ , gérés par le programme
- **Mémoire cache**
  - très rapide, très chère, capacité de quelques Mo.
- **Mémoire principale** (*Random Access Memory*)
  - assez rapide, chère, capacité allant jusqu'à quelques dizaines de Go pour les gros calculateurs
- **Disque dur**
  - lent, peu chère, grande capacité (centaines de Go), non volatile
- **Bande magnétique**
  - très grande capacité, très peu chère, accès très lent, durée de vie longue.
  - utilisé pour l'archivage, concurrencé par les disques

# Systèmes monotâches

Système monotâche → 1 seul programme en mémoire

Utilisation de cartes perforées

- lecteur de carte remplissait la mémoire
- machine dans une salle entière
- fastidieux

Apparition des bandes magnétiques

- programme chargé en mémoire exécute les calculs et fait des opérations d'E/S
- chargement de données à l'exécution
- lecture sur la bande magnétique très lente



# Systèmes multitâches

Système multitâche → plusieurs programmes chargés en mémoire

La **cohabitation** dans l'**espace mémoire** introduit de nouvelles problématiques

- Comment partager la mémoire entre les différents programmes ? Éviter le gaspillage ?
- Comment protéger les programmes les uns des autres ?
- Comment assurer le fonctionnement des programmes sans compliquer la programmation ?

# Plan

- 1 Introduction
- 2 Partage de la mémoire
  - Allocation contiguë
- 3 Adresses logiques
- 4 Gestion de l'allocation contiguë
- 5 Swapping
- 6 Segmentation
- 7 Espace mémoire paginé
- 8 Mémoire virtuelle paginée
- 9 Algorithmes de remplacement de page
- 10 Mémoire virtuelle segmentée paginée

# Partage de la mémoire

Où mettre les programmes ?

Idée : partitionner la mémoire

- mémoire physique divisée statiquement en partitions fixes
- programme chargé dans dans une zone suffisamment grande
- facile à implémenter, peu coûteux.
- gaspillage de mémoire, nombre de programmes limités

# Partage de la mémoire

Où mettre les programmes ?

Idée : partitionner la mémoire

- mémoire physique divisée statiquement en partitions fixes
- programme chargé dans dans une zone suffisamment grande
- facile à implémenter, peu coûteux.
- gaspillage de mémoire, nombre de programmes limités

Autre idée : les uns à la suite des autres

→ allocation contiguë


- partition de taille dynamique
- création à la volée en fonction de la mémoire requise, taille optimale

# Allocation contiguë

Pour chaque processus, un espace **contigu** en mémoire physique

→ une plage d'adresses

Espace mémoire



# L'allocation contiguë

Problèmes :

- Emplacement du code connu au **chargement**
- Le code doit être **indépendant** de sa position physique.
- Les espaces **alloués** sont
  - de **tailles diverses**
  - **libérés** dans un ordre imprévisible
- Comment gérer les allocations/restitutions des espaces ?


# Plan

- 1 Introduction
- 2 Partage de la mémoire
- 3 Adresses logiques
  - Indépendance code/position physique
  - Conversion adresse logique/adresse Physique
  - Protection inter-processus
  - Bilan
- 6 Segmentation
- 7 Espace mémoire paginé
- 8 Mémoire virtuelle paginée
- 9 Algorithmes de remplacement de page
- 10 Mémoire virtuelle segmentée paginée

# Indépendance code / position

Pb : Un exécutable peut être chargé à des emplacements différents (éventuellement simultanément)

Espace mémoire



Il doit fonctionner sans modification.



# Indépendance code/position physique




Chaque processus utilise des **adresses logiques**.

Le compilateur génère du **code relatif** au début du programme

- toutes les adresses sont exprimées comme si le programme était chargé à l'adresse 0
- l'**espace mémoire logique** d'un processus commence à son adresse zéro

# Indépendance code/position physique

Adresses physiques



Adresses logiques

Il faut alors traduire l'**adresse logique** utilisée dans le code en l'**adresse physique** correspondante dans la mémoire.

$$\text{adresse physique} = \text{adresse de base} + \text{adresse logique}$$

# Conversion adresse logique/adresse physique

Première solution : conversion au chargement


- Le compilateur maintient une liste de tous les endroits du où l'on effectue une manipulation d'adresse.
  - Au chargement, le système doit corriger les adresses en fonction de l'adresse de chargement du programme en suivant les indications du compilateur.
- faisable mais coûteux
- aucune protection mémoire

# Modification du matériel

Deuxième solution : conversion à l'exécution

→ Alternative matérielle

- le **registre de base** contient l'adresse de chargement du programme en mémoire.
- un **additionneur** ajoute à l'adresse logique la valeur du registre de base.



# Protection inter-processus

Comment éviter qu'un processus n'accède à l'espace mémoire d'un autre ?

# Protection inter-processus

Comment éviter qu'un processus n'accède à l'espace mémoire d'un autre ?

Une adresse logique **valide** est comprise entre


- 0
- la taille de l'espace logique (-1)

→ comparer l'adresse logique avec la taille de l'espace logique.

# Protection inter-processus

Modification du matériel : vérification des adresses logiques

- le **registre de limite** contient la taille de l'espace logique du processus en cours
  - un **comparateur** effectue la comparaison entre l'adresse logique et la valeur du registre de limite
- génère une interruption si dépassement



# Adresses logiques : Bilan

## Introduction des **adresses logiques**

- code indépendant de sa position en mémoire
- simplifie le chargement des programmes
- facilite leur protection

## Nécessite la conversion en adresse physique (réelle)

- réalisée par le **matériel**
- simple (utilisation de registres, additionneur, comparateur)
- à faible coût



# Plan

- 1 Introduction
- 2 Partage de la mémoire
- 3 Adresses logiques
- 4 Gestion de l'allocation contiguë
  - Fragmentation
  - Solutions
  - Bilan
- 5 Swapping
- 6 Segmentation
- 7 Espace mémoire paginé
- 8 Mémoire virtuelle paginée
- 9 Algorithmes de remplacement de page
- 10 Mémoire virtuelle segmentée paginée

# Gestion de l'allocation contiguë

Initialement : un espace physique **libre** en mémoire

Évolution du traitement des programmes


- **allocations** de zones (prises dans l'espace libre)
- **libération** de zones allouées

→ problème de **fragmentation**

- allocations/libérations faites dans un ordre imprévisible
- tendance à laisser des **trous**
- les trous trop petits sont inexploitable

# Fragmentation


Espace mémoire



(0) 3 processus sont présents, P2 se termine ...

# Fragmentation


Espace mémoire



(1) allocation de P4 ...

# Fragmentation


Espace mémoire



(3) allocation de P5 ...

# Fragmentation


Espace mémoire



(4) libération de P4 ...

# Fragmentation

Espace mémoire



(5) l'espace libre est fragmenté

# Remèdes à la fragmentation

Solution curative : **compactage** (relocation)

- **translater** les zones allouées pour reconstituer une grande zone libre
- nécessite de lire toute la mémoire → terriblement coûteux

Technique préventive : choix de la stratégie d'allocation

- first-fit, best-fit, worst-fit ...



# Solutions

- **first-fit** : allocation dans le premier bloc assez grand pour contenir le programme
  - le reste devient une zone libre plus petite
- **best-fit** : allocation dans le plus petit bloc qui soit assez grand
  - méthode est plus coûteuse, évite de couper inutilement une grande zone, génère plus vite de très petites zones
- **worst-fit** allocation dans le plus grand bloc
  - limite les trop petites zones, pénalisant pour les gros programmes
- autres stratégies (buddy system, quick-fit)

# Bilan

L'allocation de zones **contiguës** de tailles diverses conduit à la **fragmentation**

- problème retrouvé ailleurs (gestion des disques, new, delete en programmation, ...)
- les solutions préventives et curatives sont plus ou moins satisfaisantes

# Plan

- 1 Introduction
- 2 Partage de la mémoire
- 3 Adresses logiques
- 4 Gestion de l'allocation contiguë
- 5 Swapping
- 6 Segmentation
- 7 Espace mémoire paginé
- 8 Mémoire virtuelle paginée
- 9 Algorithmes de remplacement de page
- 10 Mémoire virtuelle segmentée paginée

# Swapping (va-et-vient)


La mémoire principale est une ressource limitée

→ peut être insuffisante pour maintenir tous les processus courants (système à temps partagé)

Idée : conserver les processus supplémentaires sur le disque et les recharger pour les exécuter.

- transférer sur disque les processus inactifs
- les ramener le moment voulu

# Swapping



Échanges mémoire ↔ disque

# Avantages

On peut charger plus de processus en **mémoire virtuelle** que la mémoire centrale ne peut en contenir

Permet d'attendre des taux de charge élevés (rentabilisation)

Viable pour les applications interactives, l'utilisateur est un périphérique très lent

# Plan

- 1 Introduction
- 2 Partage de la mémoire
- 3 Adresses logiques
- 4 Gestion de l'allocation contiguë
- 5 Swapping
- 6 Segmentation
  - Bilan
- 7 Espace mémoire paginé
- 8 Mémoire virtuelle paginée
- 9 Algorithmes de remplacement de page
- 10 Mémoire virtuelle segmentée paginée

# Segmentation

Principe : diviser l'espace mémoire en espaces logiquement indépendants (segments)

L'espace mémoire d'un processus comporte au moins deux **segments** :


- le segment de **code**
  - commun aux différentes instances du programme
  - un seul instance du code en mémoire, segment **partagé** entre les processus
- le segment de **données**
  - différent pour chaque processus

Avantages : partage segment (code, bibliothèque), économie mémoire, droits d'accès différents, ...



# Segmentation

Espace mémoire



Deux processus exécutent le même code

# Segmentation

Plusieurs *segments* → position différentes en mémoire.

Adresse logique contient le couple :

$\langle \textit{num\_segment}, \textit{offset} \rangle$


- *num\_segment* = *numéro de segment*
- *offset* = position (déplacement) dans le segment

La *table des segments* permet d'effectuer la translation entre adresse logique et adresse physique

Chaque entrée de la table contient :

- l'*adresse de base* du segment,
- la *taille* (longueur) du segment.

# Tables des segments



source : [Wikipedia](#)

# Remarque : numéros de segments

On distingue la numérotation de segment

- locale : propre à chaque processus
- globale : commune

Deux processus peuvent utiliser le même segment réel avec des numéros locaux (éventuellement) différents.

Remarque :

- La **table locale des segments** (TLS) d'un processus fournit le **numéro de segment global** à partir du **numéro de segment local**
- La **table globale de segments** (TGS) contient la description de chaque segment (longueur, pages, protections ...)

# Bilan

La segmentation permet le découpage mémoire d'un programme en plusieurs segments logiques.

- **adresse logique** représentée par un numéro de segment et une position
- utilisation d'une **table des segments**
- permet un gain de place important :
  - évite la duplication de code, segments utilisés pour les **bibliothèques communes**.

# Plan

- 1 Introduction
- 2 Partage de la mémoire
- 3 Adresses logiques
- 4 Gestion de l'allocation contiguë
- 5 Swapping
- 6 Segmentation
- 7 Espace mémoire paginé
- 8 Mémoire virtuelle paginée
- 9 Algorithmes de remplacement de page
- 10 Mémoire virtuelle segmentée paginée

# Espace mémoire paginé

Contexte : Partage de la mémoire physique par des processus

Problème : fragmentation causée par l'allocation et la libération d'espaces de tailles diverses → gaspillage de mémoire.

Idée : déporter le problème à l'intérieur des processus

- espace découpé en **pages de mêmes tailles**
- les pages d'un même espace ne sont pas forcément consécutives
- la **table des pages** indique la position en mémoire des pages d'un processus

→ **Pagination**

# Pagination

Espaces logiques découpés en **pages logiques** : souvent 4Ko.

La mémoire physique est découpée en **cadres de pages** de la même taille.

Adresse logique comprend : le numéro de page et la position dans la page.

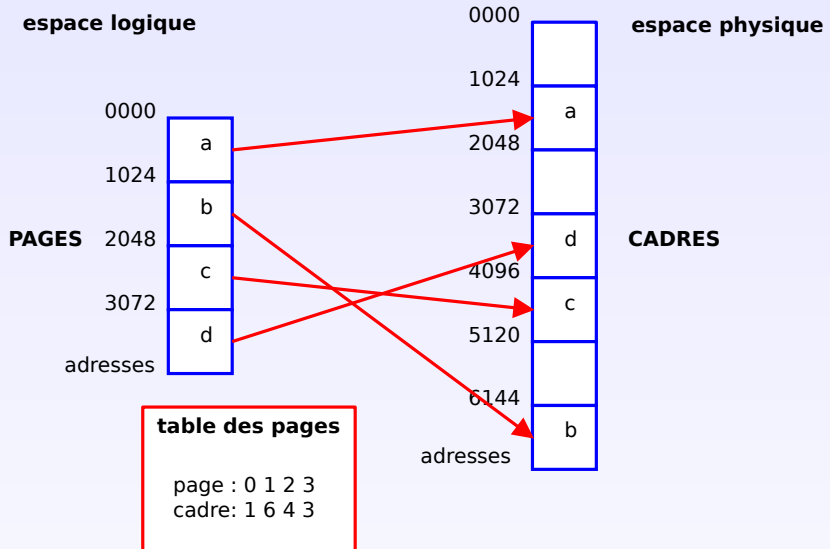
## Bits d'une adresse

Numéro de page	Position dans la page
-------------------	--------------------------

Pour chaque processus, la **table des pages** permet de retrouver la correspondance avec l'adresse physique.



# Espace paginé



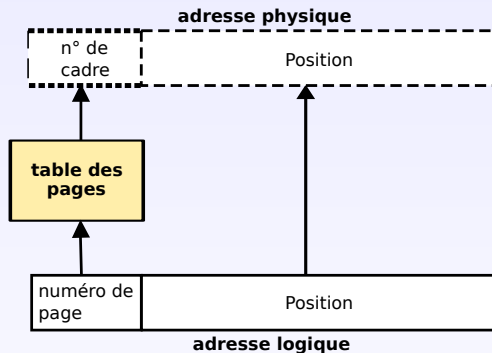
# Génération d'adresses

Le **numéro de page** est codé par les bits de poids forts

- il est converti en numéro de **cadre de page**

Les bits de poids faible donnent la **position dans la page**

- cadre de page et page logique de même taille  
→ déplacement équivalent



# Plan

- 1 Introduction
- 2 Partage de la mémoire
- 3 Adresses logiques
- 4 Gestion de l'allocation contiguë
- 5 Swapping
- 6 Segmentation
- 7 Espace mémoire paginé
- 8 Mémoire virtuelle paginée
  - Unité de Gestion Mémoire (MMU)
- 9 Algorithmes de remplacement de page
- 10 Mémoire virtuelle

# Mémoire virtuelle paginée

Principe : combinaison de la pagination et du swapping.

- la table des pages connaît les pages présentes
- interruption en cas de défaut de page (la page référencée n'est pas en mémoire)

# Unité de Gestion Mémoire (MMU)

Circuit spécialisé **Memory Management Unit**

En charge de :


- la translation d'adresses logiques (virtuelles) en adresses physique
- La protection mémoire
- contrôle de cache
- l'arbitrage du bus

# En cas de défaut de page

Le système d'exploitation reprend la main

- S'il y a des cadres vides, il ramène les pages demandées.
- Sinon il évacue une page sur disque pour libérer un emplacement
- il installe la page manquante,
- met à jour la MMU
- et relance l'instruction interrompue.

# Swapping



# Plan

- 1 Introduction
- 2 Partage de la mémoire
- 3 Adresses logiques
- 4 Gestion de l'allocation contiguë
- 5 Swapping
- 6 Segmentation
- 7 Espace mémoire paginé
- 8 Mémoire virtuelle paginée
- 9 Algorithmes de remplacement de page
- 10 Mémoire virtuelle segmentée paginée



# Algorithmes de remplacement de page

**Comment choisir la page à remplacer ?** Idéal : choisir la page qui sera utilisée le plus tard possible (voir plus du tout). Pour choisir un emplacement à libérer, en général on choisit les pages *les moins utiles*

Plusieurs algorithmes :

- FIFO
- LRU (Least Recently Used)
- NRU : Not Recently Used

# Plan

- 1 Introduction
- 2 Partage de la mémoire
- 3 Adresses logiques
- 4 Gestion de l'allocation contiguë
- 5 Swapping
- 6 Segmentation
- 7 Espace mémoire paginé
- 8 Mémoire virtuelle paginée
- 9 Algorithmes de remplacement de page
- 10 Mémoire virtuelle segmentée paginée

# Mémoire virtuelle segmentée paginée

Une adresse virtuelle comporte un numéro de segment, et un déplacement.

- chaque processus possède ses numéros de segment.
- chaque segment est composé de pages.

# Implémentation

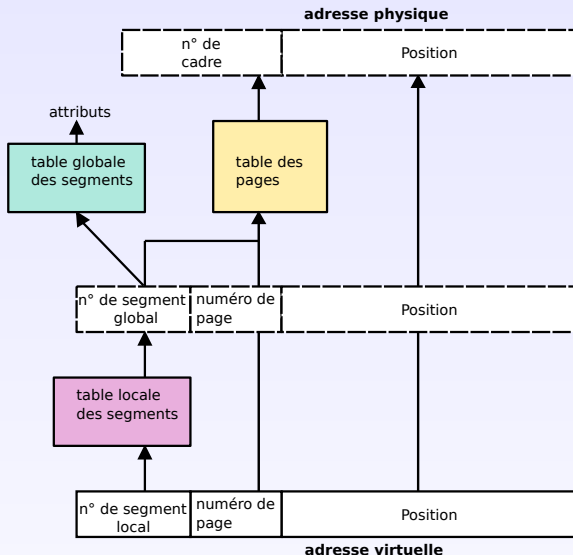
La table (TLS) traduit le numéro de segment local en numéro de segment global

Le couple (numéro de segment global, numéro de page) permet de retrouver le numéro de cadre de page correspondant


Le numéro de cadre de page et la position dans la page forment l'adresse physique.

La MMU utilise une mémoire associative pour mémoriser les correspondances  
(numéro de segment global, num. de page → numéro de cadre de page)

# Génération d'adresse



# Combinaison avec le swapping



# Bilan

Combinaison de :

- pagination,
- segmentation,
- swapping

Permet :

- la cohabitation entre les processus
- la protection
- les zones partagées
- l'économie mémoire

Technique largement adoptée depuis les années 70